

BÁO CÁO THỰC HÀNH LAB 2 ĐẶC TRƯNG TIẾNG NÓI VÀ NHẬN DẠNG BẰNG MFCC + DTW

Học phần	CSE457 - Xử lý âm thanh và tiếng nói
Sinh viên	Nguyễn Ngọc Tiến
Mã sinh viên	2351260688
Bộ từ nhận dạng	down, go, left, right, up
Đánh giá	Mixed-quality, cross-speaker
Ngày hoàn thiện	05/10/2026

Hà Nội, 2026

MỤC LỤC

1. Tóm tắt kết quả	3
2. Dữ liệu, tiền xử lý và cấu hình	3
2.1. Tập dữ liệu, chất lượng và phân chia	3
2.2. Bảng tham số	4
3. Energy, ZCR và endpoint detection	5
3.1. Đặc trưng miền thời gian	5
3.2. Endpoint detection	6
4. Trích chọn đặc trưng MFCC	7
5. DTW tự cài đặt	8
6. Bộ nhận dạng và kết quả đánh giá	9
7. Thí nghiệm đối chứng E1-E2	11
8. Trả lời câu hỏi báo cáo	12
9. Kết luận và hướng cải tiến	14

Bản báo cáo này đã được hiệu chỉnh theo đúng output notebook đã chạy: bổ sung mô tả mixed-quality/cross-speaker, cảnh báo clipping, đủ 3 đồ thị Energy/ZCR, bảng top-3 cho 5 tệp test và sửa cột kết quả Đúng/Sai.

1. Tóm tắt kết quả

Bài thực hành xây dựng bộ nhận dạng 5 từ đơn tiếng Anh: down, go, left, right, up. Pipeline gồm framing, Energy/ZCR, endpoint detection, MFCC, DTW tự cài đặt và nearest-template. Bộ dữ liệu đánh giá gồm 25 tệp, trong đó 15 tệp làm template và 10 tệp làm test; không có tệp xuất hiện đồng thời ở hai tập.

Chỉ số	Kết quả	Diễn giải
Accuracy baseline	50,00% (5/10)	Endpoint + MFCC13 + DTW
E1 - không trim	60,00%	Cao hơn cấu hình có trim 10 điểm %
E1 - có trim	50,00%	Endpoint hiện tại chưa cải thiện accuracy
E2 - MFCC13	50,00%	Mốc so sánh
E2 - MFCC13 + Delta	40,00%	Giảm 10 điểm %
DTW(X, X)	0,0000	Kiểm tra cài đặt đạt yêu cầu

Kết luận chính: pipeline hoạt động đúng nhưng độ chính xác chỉ 50%. Đây là một split khó hơn baseline sạch trước đó vì dữ liệu hiện tại có ý trộn chất lượng tốt/kém và tách speaker giữa train/test. Do test chỉ có 10 tệp, các kết luận cần được hiểu là kết quả trên split hiện tại, chưa phải ước lượng tổng quát cho mọi người nói.

2. Dữ liệu, tiền xử lý và cấu hình


2.1. Tập dữ liệu, chất lượng và phân chia

Mỗi lớp có 5 tệp WAV, tổng cộng 25 tệp. Output notebook xác nhận tất cả tệp đều mono, 16 kHz và dài 1,000 s. Ba tệp đầu mỗi lớp được dùng làm template; hai tệp cuối làm test.

Bộ 25 tệp được tuyển chọn theo mixed-quality: mỗi lớp có 3 mẫu GOOD và 2 mẫu POOR. Tập train/template gồm 10 GOOD + 5 POOR; tập test gồm 5 GOOD + 5 POOR. Ba speaker của train (a1cff772, c948d727, 38d78313) không xuất hiện trong test; hai speaker test là 8134f43f và 0137b3f4. Vì vậy đây là đánh giá cross-speaker, không nên mô tả là speaker-dependent.

Lớp	Số tệp	Train/template	Test	Chất lượng/lớp
down	5	down_01-03	down_04-05	3 GOOD + 2 POOR
go	5	go_01-03	go_04-05	3 GOOD + 2 POOR
left	5	left_01-03	left_04-05	3 GOOD + 2 POOR
right	5	right_01-03	right_04-05	3 GOOD + 2 POOR
up	5	up_01-03	up_04-05	3 GOOD + 2 POOR

Kiểm tra biên độ phát hiện hai tệp được gắn cờ possible_clipping theo tiêu chí peak $\geq 0,999$: right_02.wav (peak = 1,000000) và up_04.wav (peak = 0,999969). Đây là cảnh báo dựa trên peak, không phải khẳng định chắc chắn toàn tín hiệu bị clipping.



Hình 1. Waveform của ba từ mẫu down, go và left; vùng tiếng nói nằm giữa các đoạn silence.


2.2. Bảng tham số

Thành phần	Giá trị	Vai trò
Tần số lấy mẫu	16.000 Hz	Đồng nhất dữ liệu train/test
Frame / hop	25 ms / 10 ms	400 mẫu / 160 mẫu; chồng lấn 15 ms
Cửa sổ	Hamming	Giảm spectral leakage
Pre-emphasis	$\alpha = 0,97$	Tăng tương đối thành phần tần số cao
FFT	NFFT = 512	Tính phổ công suất từng frame
Mel filterbank	24 bộ lọc	Phân giải theo thang Mel
MFCC	13 hệ số + CMN	Vector đặc trưng cố định theo frame
Endpoint	$\Delta E = 30 \text{ dB}$; margin 50 ms	Ngưỡng tương đối và vùng đệm
Local distance	Euclidean	Khoảng cách giữa hai vector MFCC
DTW	3 bước; cost / path	Căn chỉnh và chuẩn hóa theo đường đi


3. Energy, ZCR và endpoint detection

3.1. Đặc trưng miền thời gian


Với frame đã nhân cửa sổ $x_r[n]$, năng lượng ngắn hạn được tính bởi $E_r = \sum x_r^2[n]$, $RMS = \sqrt{E_r/L}$, còn ZCR đo số lần đổi dấu trung bình trên một mẫu. Silence có log-energy rất thấp; voiced thường có energy cao và ZCR thấp hơn, trong khi vùng vô thanh/fricative có thể có energy thấp hơn nhưng ZCR tăng.



Hình 2. Waveform, log-energy và ZCR của down_01.wav.




Hình 3. Waveform, log-energy và ZCR của go_01.wav.



Hình 4. Waveform, log-energy và ZCR của `left_01.wav`.

Ba đồ thị cho thấy Energy/ZCR biến thiên rõ theo cấu trúc âm học từng từ. Các đoạn silence có mức năng lượng rất thấp; phần tiếng nói làm log-energy tăng mạnh. Ở một số biên/đoạn vô thanh, ZCR tăng dù energy giảm, vì vậy endpoint không nên chỉ dựa trên energy.

3.2. Endpoint detection



Hình 5. Endpoint của `down_01.wav`; đường đứt thể hiện start/end và các ngưỡng.

Với `down_01.wav`, thời lượng giảm từ 1,000 s xuống 0,575 s; `start` = 0,150 s, `end` = 0,725 s. Hàm dùng ngưỡng log-energy tương đối (max - 30 dB), ZCR để tinh chỉnh nhẹ và margin 50 ms ở hai biên.


Thống kê endpoint trên 25 tệp

Thống kê 25 tệp	Trước trim	Sau trim
Trung bình	1,000 s	0,715 s
Nhỏ nhất	1,000 s	0,295 s
Lớn nhất	1,000 s	1,000 s

Tập ngắn nhất sau trim là up_05.wav (0.295 s). Một số tệp giữ nguyên 1,000 s. Cùng với E1 (accuracy giảm từ 60% khi không trim xuống 50% khi trim), output cho thấy heuristic endpoint hiện tại chưa ổn định trên toàn bộ dữ liệu. Cần nghe lại các tệp biên, đặc biệt tệp bị cắt rất ngắn, trước khi kết luận không mất phụ âm.

4. Trích chọn đặc trưng MFCC

Pipeline nhất quán cho train/test: pre-emphasis -> framing/Hamming -> FFT/power -> 24 Mel filters -> log -> DCT -> 13 MFCC -> CMN. Log nén dynamic range, còn DCT biến các log-energy filterbank thành các hệ số cepstral gọn hơn.




Hình 6. Heatmap MFCC của down_01 (55x13) và go_01 (50x13).

Hai tệp có số frame khác nhau vì vùng tiếng nói sau trim có thời lượng khác nhau; số chiều mỗi frame luôn bằng 13 do n_mfcc cố định. Chính chuỗi ma trận $T \times 13$ là đầu vào của DTW.

5. DTW tự cài đặt

Local distance giữa frame i và j là $d(i,j) = ||x_i - y_j||_2$. Ma trận tích lũy dùng ba bước trên, trái, chéo: $D[i,j] = d(i,j) + \min(D[i-1,j], D[i,j-1], D[i-1,j-1])$. Sau backtracking, chỉ phí được chuẩn hóa theo độ dài optimal path: $DTW_norm = D[N-1,M-1] / |P|$. Kiểm tra đồng nhất cho kết quả $DTW(X,X) = 0$.



Hình 7. Local-distance matrix và optimal path: cùng từ down (trái), khác từ down-go (phải).

Cặp so sánh	DTW_norm	Quan sát đường đi
Cùng từ: down	47,0831	Nhiều đoạn ngang/dọc; chênh thời lượng rõ
Khác từ: down - go	33,2880	Tương đối gần đường chéo; ít biến dạng hơn


Kết quả minh họa là một ngoại lệ so với kỳ vọng: cặp cùng từ có cost cao hơn cặp khác từ. Điều này không chứng minh DTW sai vì $DTW(X,X)=0$; nó cho thấy một cặp riêng lẻ có thể chịu ảnh hưởng mạnh của speaker, chất lượng âm thanh, tốc độ nói và biên trim. Vì vậy recognizer dùng nhiều template/lớp và lấy cost nhỏ nhất.

6. Bộ nhận dạng và kết quả đánh giá

Với mỗi tệp test, hệ thống trích feature, tính DTW đến toàn bộ 15 template, lấy cost nhỏ nhất theo từng lớp và chọn nhãn có cost thấp nhất. Bảng dưới giữ nguyên top-1/top-2 từ output notebook; cột cuối dùng chữ Đúng/Sai để tránh lỗi glyph khi xuất PDF.

Tệp test	Nhân thật	Dự đoán	Top-1 / score	Top-2 / score	KQ
down_04.wav	down	up	up / 50.7671	down / 56.5251	Sai
down_05.wav	down	down	down / 37.3522	go / 42.3534	Đúng
go_04.wav	go	go	go / 48.5997	up / 53.3845	Đúng
go_05.wav	go	go	go / 38.6508	down / 45.3828	Đúng
left_04.wav	left	up	up / 47.3178	go / 53.0652	Sai
left_05.wav	left	right	right / 44.4478	left / 49.5312	Sai
right_04.wav	right	up	up / 54.5930	left / 57.5244	Sai
right_05.wav	right	right	right / 41.2456	up / 50.2663	Đúng
up_04.wav	up	up	up / 42.8139	right / 44.0732	Đúng
up_05.wav	up	go	go / 33.1799	down / 36.1204	Sai

Mô hình nhận đúng 5/10 tệp. Lớp go đạt 2/2; down, right và up đạt 1/2; left đạt 0/2. Các lỗi ngoài đường chéo đều xuất hiện một lần, nên không có một cặp nhầm duy nhất nổi trội theo số đếm. Xét theo lớp, left là lớp khó nhất vì cả hai mẫu test đều bị nhầm.



Hình 8. Confusion matrix baseline; accuracy = 50,00%.

Top-3 nhãn gần nhất cho 5 tệp test

Tệp	Top-1	Top-2	Top-3
down_04.wav	up / 50,7671	down / 56,5251	left / 57,9671
down_05.wav	down / 37,3522	go / 42,3534	up / 49,0793
go_04.wav	go / 48,5997	up / 53,3845	down / 55,9439
go_05.wav	go / 38,6508	down / 45,3828	up / 52,3290
left_04.wav	up / 47,3178	go / 53,0652	left / 54,4686

Ví dụ down_04 bị dự đoán thành up với score 50,7671 trong khi nhãn đúng down có score 56,5251; chênh lệch 5,7580. left_04 cũng cho thấy nhãn đúng chỉ đứng thứ ba. Các khoảng cách gần nhau phản ánh ranh giới template chưa ổn định trong điều kiện cross-speaker và mixed-quality.

7. Thí nghiệm đối chứng E1-E2

Mã	Thiết lập	Accuracy	Chênh lệch	Nhận xét
E1	Không endpoint	60,00%	+10 điểm %	Tốt hơn cấu hình có trim trên split này
E1	Có endpoint	50,00%	Mốc so sánh	Heuristic trim chưa ổn định
E2	MFCC13	50,00%	Mốc so sánh	Baseline feature
E2	MFCC13 + Delta	40,00%	-10 điểm %	Đặc trưng động chưa giúp trên split nhỏ

Nhận xét E1

Không trim đạt 60%, còn có trim đạt 50%. Kết quả này cho thấy endpoint detection không mặc nhiên làm tăng accuracy. Vì mọi clip gốc đều dài 1 s, việc giữ nguyên biên có thể vô tình giúp DTW trên split hiện tại; ngược lại, trim không đồng đều (0,295-1,000 s) có thể làm chuỗi MFCC biến thiên mạnh hơn. Đây là diễn giải từ output, không phải kết luận rằng silence luôn có lợi.

Nhận xét E2

MFCC13 + Delta đạt 40%, thấp hơn MFCC13 10 điểm %. Trên bộ dữ liệu nhỏ và có mẫu nhiễu, đặc trưng động làm tăng chiều từ 13 lên 26 và có thể nhạy hơn với sai khác cục bộ/biên endpoint. Kết luận chỉ áp dụng cho 10 mẫu test hiện tại; cần nhiều split hoặc leave-one-out để đánh giá ổn định hơn.

Điểm cần nhấn mạnh trong báo cáo: hai thay đổi khó xảy ra đồng thời ở bộ dữ liệu mới - mixed-quality và cross-speaker. Vì vậy mức 50% không thể quy hoàn toàn cho riêng noise hay riêng speaker; muốn tách ảnh hưởng cần thí nghiệm có kiểm soát.

8. Trả lời câu hỏi báo cáo

1. Vì sao không nên dùng toàn bộ waveform làm template chính khi hai utterance có thời lượng khác nhau?

Waveform thô phụ thuộc mạnh vào lệch pha, biên độ, vị trí bắt đầu và tốc độ nói. Hai lần nói cùng từ có thể có số mẫu khác nhau nên không thể so từng mẫu trực tiếp. MFCC gom thông tin theo frame và giảm ảnh hưởng pha; DTW căn chỉnh phi tuyến theo thời gian nên phù hợp hơn.

2. Vai trò khác nhau của short-time energy và ZCR trong endpoint detection?

Energy phát hiện vùng có công suất nổi bật so với nền, phù hợp với phần hữu thanh. ZCR hỗ trợ nhận biết phụ âm vô thanh/fricative: các vùng này có thể có energy thấp nhưng số lần đổi dấu cao. Kết hợp hai đại lượng và margin giúp hạn chế cắt mất âm đầu/cuối.

3. Vì sao Mel filterbank có khoảng cách theo Hz rộng dần khi tần số tăng?

Thang Mel phản ánh cảm nhận tần số phi tuyến của tai người. Các điểm cách đều trên Mel khi đổi ngược sang Hz sẽ thưa dần ở tần số cao, vì vậy filterbank rộng hơn ở vùng cao và có độ phân giải dày hơn ở vùng thấp.

4. Log và DCT trong MFCC có tác dụng gì?

Log nén dynamic range và biến quan hệ nhân thành gần cộng. DCT biến 24 log-energy filterbank thành các hệ số cepstral ít tương quan hơn; 13 hệ số đầu chủ yếu mô tả đường bao phổ.

5. Ý nghĩa của bước ngang, bước dọc và bước chéo trong ma trận DTW?

Bước chéo ghép một frame X với một frame Y. Bước ngang giữ frame X và đi qua thêm frame Y; bước dọc giữ frame Y và đi qua thêm frame X. Hai bước ngang/dọc biểu diễn kéo giãn hoặc nén thời gian, còn tính đơn điệu giữ đúng thứ tự phát âm.

6. Tại sao phải chuẩn hóa DTW cost theo path length?

Nếu chỉ dùng tổng cost, utterance dài thường tích lũy nhiều local distance hơn và bị bất lợi. Chia cho số cặp frame trên đường tối ưu tạo chi phí trung bình, giúp so sánh công bằng hơn giữa các chuỗi có thời lượng khác nhau.

7. Ba nguyên nhân làm cùng một từ có MFCC khác nhau giữa hai lần nói?

Tốc độ/trường độ phát âm; cao độ, cường độ và cách nhấn; người nói, vị trí micro, đáp tuyến thiết bị và nhiễu nền. Ngoài ra endpoint có thể giữ/cắt biên khác nhau.

8. Cặp từ dễ nhầm nhất và nguyên nhân?

Các lỗi ngoài đường chéo đều đồng hạng một lần: down->up, left->right, left->up, right->up và up->go. Do đó không nên khẳng định một cặp duy nhất là dễ nhầm nhất chỉ từ số đếm. Xét theo lớp, left khó nhất vì 0/2 mẫu đúng. down_04 có up=50,7671 và down=56,5251; left_05 có right=44,4478 và left=49,5312. Nguyên nhân có thể gồm khác biệt speaker, chất lượng tín hiệu, endpoint và template chưa bao phủ đủ biến thiên.

9. Hạn chế của DTW với người nói mới; nội dung Chương 3 nào phù hợp hơn?

DTW phụ thuộc template nên khoảng cách tăng khi giọng, cao độ, tốc độ và kênh thu của người nói mới khác tập mẫu; số template cần lưu và chi phí so sánh cũng tăng. Các mô hình âm học thống kê như HMM, kết hợp mô hình trạng thái/phoneme và huấn luyện trên nhiều người nói ở Chương 3, có khả năng khái quát tốt hơn.

9. Kết luận và hướng cải tiến

Bài Lab đã hoàn thành pipeline nhận dạng từ đơn MFCC + DTW, bao gồm Energy/ZCR, endpoint detection, MFCC, dynamic programming/backtracking DTW tự cài đặt, nearest-template, top-3, confusion matrix và hai thí nghiệm bắt buộc E1-E2. Accuracy baseline đạt 50%; cấu hình không trim đạt tốt nhất 60%.

So với bộ dữ liệu sạch trước đó, split hiện tại khó hơn vì cố ý trộn chất lượng tốt/kém và tách speaker giữa train/test. Kết quả vì vậy phản ánh rõ hơn hạn chế của template matching khi điều kiện thu và người nói thay đổi. Tuy nhiên, test chỉ có 10 mẫu nên chưa đủ để suy rộng.

Các cải tiến ưu tiên

- Tăng số lần ghi và số template/lớp; giữ cân bằng train/test và tránh data leakage.
- Nghe lại các tệp trimmed, đặc biệt up_05 (0,295 s), tăng margin hoặc ước lượng noise floor thích nghi.
- Kiểm tra riêng right_02 và up_04 do được gắn cờ possible_clipping.
- Phân tích các lỗi left->right/up, down->up bằng waveform, MFCC và DTW path.
- Đánh giá lại bằng nhiều split, leave-one-out hoặc tăng số mẫu test.
- Tách riêng thí nghiệm ảnh hưởng của quality và speaker để tránh thay đổi hai yếu tố cùng lúc.

Tài liệu và sản phẩm đối chiếu

Nguồn	Vai trò trong báo cáo
Lab 2.pdf	Yêu cầu A-G, 9 câu hỏi, sản phẩm nộp và tiêu chí chấm điểm
Lab2_MFCC_DTW_data_down_go_left_right_up(2).ipynb	Mã nguồn, tham số và output đã chạy
selection_report.csv	Thông tin GOOD/POOR và speaker của bộ 25 tệp tuyển chọn
results.csv	Kết quả dự đoán top-1/top-2 cho 10 tệp test
experiments_E1_E2.csv	Kết quả thí nghiệm endpoint và MFCC+Delta
figures/	Waveform, Energy/ZCR, endpoint, MFCC, DTW path, confusion matrix

Tài liệu tham khảo nền tảng: Huang, Acero & Hon (2001); Rabiner & Schafer (2011); Jurafsky & Martin (2008); đề cương CSE457 - Xử lý âm thanh và tiếng nói, Trường Đại học Thủy Lợi.